

文献调研：softmax attention 中的 in-context policy improvement

调研日期：2026-08-11 · 服务于 icrl softmax 研究线 目的：确认"softmax attention 能否做构造性的 policy improvement"这一空白的真实性与边界

Abstract (摘要)

本调研回答一个问题：在 softmax 归一化的 attention 中，是否存在构造性的、类似 Q-learning 的 policy improvement (策略改进) 结果？

结论分三层：

1. 空白成立。softmax attention 侧的构造性理论目前只有评估 (唯一一篇：2605.07333)；所有构造性的"改进算子" (半梯度、max bootstrap、GD) 都在线性/ReLU attention 或 bandit 自改进 一侧。
2. 两条硬证据解释空白为何存在：softmax 输出被限制在输入 token 的凸包内 (2005.09561, 权重全正、和为 1, 带符号更新被禁)；softmax 尖峰随序列增长弥散 (2410.01104)。
3. 我们的工作落在格子里： $\delta \cdot \text{softmax}(\delta/\tau) \cdot \phi$ (score-scaled softmax) 这类"把 δ 乘回权重"的实现，检索不到任何直接对应文献——最近邻居是线性侧的 2605.05755 与 softmax 评估侧的 2605.07333，两者之间无人。

1. 引言 (为什么需要这份调研)

本研究 (icrl softmax) 尝试把 in-context policy improvement (注意力模型在轨迹输入下实现策略改进，而非仅评估) 从线性 attention 推进到 softmax attention。写论文前必须回答一个问题：

"softmax + 改进"这一格，是不是真的没人站？

如果别人做过了，我们就是重复劳动；如果没人做，我们需要知道为什么没人做——是"没人想到" (低垂果实)，还是"有硬障碍" (前人的坑在等我们踩)。这两者决定了论文的定位和难度。

本调研给出结论：没人做，且有两条结构性的障碍证据。这既确认了空白 (novelty 成立)，也预告了难点 (为什么我们的方法有边界，见夜间报告 §19 的"评估值自包含"卡点)。

2. 研究问题 (Research Questions)

三个问题，按"支持贡献的空白 → 机制实现 → 边界"三块设计：

- RQ1: softmax/归一化 attention 里有哪些构造性的 policy improvement 结果？ (支撑"novelty": 我们的贡献是不是新的)
- RQ2: 把"改进算子"放进 attention 的权重或读出，有哪些实现方式？ (支撑"mechanism": 半梯度 / max bootstrap / score-scaled 各是谁做的)
- RQ3: 评估值的自包含 (bilinear 的 $Q=\phi \cdot w$ 由 token 自己重推导出来) 在 attention 里有没有被研究过？ (支撑"边界": 我们卡在评估值自包含，看别人有没有解过)

3. 分类框架 (MECE Taxonomy)

检索到的全部相关文献，按"方法阵营 × 是否改进"划分，保证不重叠、不遗漏：

阵营	定义	代表文献	数量
线性改进 (lin_improve)	线性/ReLU	2605.05755,	3
	attention, 构造性做改进	2603.01335,	
	算子	2310.08566	
softmax 评估 (sm_eval)	softmax		1
	attention, 构造性做评估 (Q/V 函数)	2605.07333	

阵营	定义	代表文献	数量
softmax (sm_emulate)	算法模拟 softmax attention 模拟 GD/回归等更新算子	2508.17550, 2510.10425, 2605.06609	3
障碍证据 (obstacle)	证明 softmax 结构限制的理论	2005.09561, 2410.01104 2605.10466,	2
bilinear 读出 / 自包含 (bilinear)	attention 输出 = 双线性读出; 权重自包含	2212.07677, 2211.15661, 2307.03576	4
决策类 (旁支) (decision)	注意力做决策但不是本研 究的构造性改进	2106.01345, 2306.14892, 2605.09867	3

术语陷阱（必须排除）：策略分布 $\pi(a) \propto \exp(Q/\tau)$ （也叫 softmax policy / Boltzmann policy）是另一个成熟领域，与“注意力权重 softmax”完全无关。检索时如果把它算进去，会误判空白不存在。本调研一律排除。

4. 分支比较（各阵营细读）

4.1 线性改进（lin_improve）——改进算子的“老家”

[2605.05755] Liang & Lai, 2026《Transformers Provably Implement In-Context RL with Policy Improvement》：线性 self-attention 单块可显式构造实现半梯度 SARSA 与 actor-critic，带收敛证明。这是“改进算子放进 attention”的最直接先例——但在线性侧（无归一化）。
[2603.01335] Yu et al., 2026 (ICPO)：单层线性 self-attention 在 Fisher 加权 logit-matching 预训练下模仿 linear bandits 的策略优化。注意是“test-time 自我改进”设定，非经典 ICRL 控制。
[2310.08566] Lin, Bai, Song, 2023《Transformers as Decision Makers》：ReLU attention 逼近 LinUCB/TS/UCB-VI 等在线 RL 算法。决策类，非 bootstrap 改进。

共同点：全部用无归一化的 attention（线性/ReLU）。改进需要的带符号更新，在无归一化下是自由的。

4.2 softmax 评估（sm_eval）——唯一的一篇

[2605.07333] Xie, Liu, Chen, D. Liu, Chandra, Zhang, 2026《Beyond Linear Attention: Softmax Transformers Implement In-Context RL》：唯一真正 softmax attention 的构造性论文。dual-head 层前向等价于带 softmax 加权的非参数 TD 更新（Berthier 式批版），在核空间做评估。只评估，不改进。

注意：经逐篇核验，曾被归入“softmax 评估阵营”的 2605.07123 (CoT)、2405.13861 (TD)、2509.18389 (Emergence) 三篇，理论部分实际上都用线性 attention 简化证明。真正的 softmax 构造性评估只有 2605.07333 一篇。→ 空白比预想更薄、更扎实。

4.3 softmax 算法模拟（sm_emulate）——softmax 能做更新算子的证据

[2508.17550] Hu et al., 2025：冻结权重 softmax attention 可精确模拟 $f(w^T x - y)$ ，涵盖 GD、线性/ridge 回归。softmax 能做正加权更新算子的证据。
[2510.10425] Dragutinovi, Saxe, Singh, 2025：softmax $\geq$ linear——softmax transformer 可按核梯度下降学习 in-context 分类。softmax 的非线性映射到核空间后就是 GD。
[2605.06609] Zhang & Cao, 2026：softmax transformer 经归一化 GD 高效做 in-context logistic 回归。

共同点：证明 softmax 能做梯度型更新，但都在核空间 / 正加权。这里的关键区分：这些更新的“符号信息”由 y （标签）提供，是外生监督；而我们需要的改进是从 δ 内生出的带符号方向——后者撞凸包约束（见 4.4）。

4.4 障碍证据 (obstacle) ——为什么空白存在

- [2005.09561] Richter & Wattenhofer, 2020 《Normalized Attention Without Probability Cage》: attention 权重被限制在概率单纯形 $\rightarrow$ 输出落在值的凸包内。带符号 / 越界更新被禁止。 $\rightarrow$ 这直接解释了我们框架里“纯凸组合 (δ 不乘回) 死”的现象: softmax 归一化吃掉了 δ 的符号。
- [2410.01104] Velikovi et al., 2024 《Softmax is not Enough (for Sharp Size Generalisation)》: 即使“找最大值”这类任务, softmax 尖峰也随序列长度增长而弥散。 $\rightarrow$ 解释了“尖峰读不出可靠方向”的第二个结构性限制。

4.5 bilinear 读出 / 自包含 (bilinear) ——RQ3 的邻居

- [2605.10466] Xu & Fang, 2026 《Self-Attention as a Covariance Readout》: softmax 输出几乎必然收敛到 $\theta V \cdot \Sigma \cdot \theta K^T \cdot \theta Q \cdot x$ ——协方差读出, bilinear 结构, 单头 = 一步 population GD。这是最接近我们“评估值自包含 $Q = \phi \cdot w$ ”的 softmax 侧工作 (但它是正定协方差, 读不出带符号的方向)。
- [2212.07677] von Oswald et al., 2022: 线性 transformer 通过内隐梯度下降学习 in-context (线性阵营自包含的源头)。
- [2211.15661] Akyürek et al., 2023: 证明线性 transformer 可实现 GD 与 ridge 回归逆算——权重自包含 (线性阵营)。
- [2307.03576] Mahankali, Hashimoto, Ma, 2023: 单步 GD 是单层线性 self-attention 的最优 in-context learner。(注: 此篇不是 ridge 逆算那篇——ridge 逆算是 Akyürek 的; 两者常被混记, 已更正。)

4.6 决策类 (decision) ——旁支

- [2106.01345] Chen et al., 2021 (Decision Transformer): attention 做条件行为克隆, 非构造性改进。
 - [2306.14892] Lee et al., 2023 (DPT): 监督预训练可学 in-context RL (行为克隆式)。
 - [2605.09867] Anand et al., 2026: 连续 latent context token 里做 weighted majority + Q-learning, 状态存于 latent token (线性组合嵌入), 非“注意力权重读出”。(注: 最初记忆的标题“softmax 精确实现 tabular Q-learning”与该文不符, 已更正——它是隐式 CoT 状态, 非 softmax 权重构造。)
-

5. 讨论 (把证据串起来)

空白成立, 且是“有障碍的空白”:

- 改进算子的构造理论 (RQ1/RQ2 线性侧) 全部在无归一化 attention。softmax 侧只有评估 (1 篇)。
 - 两条结构障碍 (凸包 2005.09561、弥散 2410.01104) 解释了为什么“softmax + 带符号改进”没人做成: 归一化天生与符号更新冲突。
 - 我们的方法 (C3-v3 / att td lin 的 $\delta \cdot \text{softmax}(\delta/\tau) \cdot \phi$, $\tau \rightarrow \infty$ 退化为半梯度) 部分绕过了凸包——把 δ 乘回权重, 符号从“权重符号”恢复; 但评估值自包含 (RQ3) 仍在。这与夜间报告 §19 的边界完全一致: 能做改进, 但评估值无法自给。
 - 最接近邻居: 2605.05755 (线性改进) + 2605.07333 (softmax 评估)。我们的论文是在两篇之间的格子里填第一笔。
-

6. Open Problems (我们能贡献的开放问题)

1. softmax 阵营的构造性评估也极薄 (只有 1 篇) ——评估侧的空白同样可以写。
 2. 带符号更新的凸包绕过: $\delta \cdot \text{softmax}(\delta/\tau)$ 的收敛性质、 τ 的退火行为, 无人研究。
 3. 评估值自包含 (RQ3): bilinear $Q = \phi \cdot w$ 由 token 自给, softmax 侧无解; 2605.10466 的协方差读出是正定的, 读不出符号——这是边界, 也可能是新方向。
-

7. 结论 (逐条回答 RQ)

- RQ1 (softmax 构造性改进): 空白成立。softmax 侧仅 2605.07333 一篇做评估; 改进算子全部在线性/ReLU/bandit 侧。最近邻居 = 2605.05755 (线性改进) + 2605.07333 (softmax 评估)。
- RQ2 (改进算子放进 attention): 线性侧已有半梯度 $\delta \cdot \phi$ (2605.05755); softmax

侧仅评估型"softmax 加权 TD" (2605.07333, softmax 加在 QK 相似度上, 不是加在 δ 上)。 $\delta \cdot \text{softmax}(\delta/\tau) \cdot \phi$ 这类"softmax(δ)"版本检索不到对应文献。 softmax 能做的梯度更新在核空间/正加权 (2508.17550, 2510.10425, 2605.06609) , 符号来自外生监督 y , 非内生 δ 。

- RQ3 (评估值自包含) : 有邻居, 无直解。 softmax 侧最近的是协方差读出 (2605.10466, bilinear 但正定) ; 线性阵营有完整自包含 (2212.07677, 2211.15661) ; softmax 直接"Q= ϕ ·w 由 token 自给"尚无。
-

8. References (全部经 arXiv 逐篇核验)

线性改进 - [2605.05755] H. Liang, L. Lai. Transformers Provably Implement In-Context Reinforcement Learning with Policy Improvement. 2026. - [2603.01335] T. Yu et al. Provable and Practical In-Context Policy Optimization for Self-Improvement (ICPO). 2026. - [2310.08566] L. Lin, Y. Bai, S. Mei. Transformers as Decision Makers: Provable In-Context RL via Supervised Pretraining. 2023.

softmax 评估 - [2605.07333] Z. Xie, X. Liu, C. Chen, S. D. Liu, R. Chandra, S. Zhang. Beyond Linear Attention: Softmax Transformers Implement In-Context Reinforcement Learning. 2026.

softmax 算法模拟 - [2508.17550] J. Y.-C. Hu, H. Liu, J. Y. Zhang, H. Liu. In-Context Algorithm Emulation in Fixed-Weight Transformers. 2025. - [2510.10425] S. Dragutinović, A. M. Saxe, A. K. Singh. Softmax $\geq$ Linear: Transformers may learn to classify in-context by kernel gradient descent. 2025. - [2605.06609] C. Zhang, Y. Cao. Transformers Efficiently Perform In-Context Logistic Regression via Normalized GD. 2026.

障碍证据 - [2005.09561] O. Richter, R. Wattenhofer. Normalized Attention Without Probability Cage. 2020. - [2410.01104] P. Veličković, C. Perivolaropoulos, F. Barbero, R. Pascanu. Softmax is not Enough (for Sharp Size Generalisation). 2024.

bilinear / 自包含 - [2605.10466] H. Xu, G. Fang. Self-Attention as a Covariance Readout: A Unified View of ICL and Repetition. 2026. - [2212.07677] J. von Oswald et al. Transformers learn in-context by gradient descent. 2022. - [2211.15661] E. Akyürek et al. What Learning Algorithms is In-Context Learning Using? 2023. - [2307.03576] A. Mahankali, T. B. Hashimoto, T. Ma. One Step of Gradient Descent is Provably the Optimal In-Context Learner with One Layer of Linear Self-Attention. 2023.

决策类(旁支) - [2106.01345] L. Chen et al. Decision Transformer: Reinforcement Learning via Sequence Modeling. 2021. - [2306.14892] J. N. Lee et al. Supervised Pretraining Can Learn In-Context Reinforcement Learning. 2023. - [2605.09867] E. Anand, A. Ateyeh, X. Cao, M. Dabagia. Continuous Latent Contexts Enable Efficient Online Learning in Transformers. 2026.

附录：调研方法注记（为什么这样做）

- 先宽后窄：先按"主流学派 / 障碍证据 / 相邻领域 / 决策旁支"多个视角撒网搜，再逐篇收窄。不先宽，会漏掉"别人做过了"；不收窄，会混进策略 softmax 那几万篇。
- 每篇两步验证（存在性 + 元数据）：用 arXiv API/页面核对 ID、标题、作者。本调研中因此纠正了 3 处记忆错误 (2605.07123/2405.13861/2509.18389 实为线性、2307.03576 描述不符) ——不验证就会把错文献写进论文，这是科研硬伤。
- MECE 分类：MECE = 相互独立 (Mutually Exclusive)、完全穷尽 (Collectively Exhaustive)。分类后每篇只属于一格，且所有相关文献都有归属，这样"空白"的论证才站得住。
- 这一步为什么决定论文生死：novelty (新不新) 在审稿里是 first-order。空白论证只要有一篇漏网之鱼，审稿人一句话就能推翻整篇贡献。所以调研宁慢勿虚。