

标准 Softmax 注意力支持上下文内策略改进

匿名作者

关键词：上下文内强化学习；softmax 注意力；策略改进；SARSA；Expected SARSA；近似贪心化

第一种构造从原始 transition token 与持久化 Q-memory token 出发。在一个精确定义的双 block residual attention-FFN 网络中，两个 retrieval head 读取当前 pair 与采样得到的下一 pair 的 Q 值，固定 ReLU 映射形成带符号 sampled-SARSA residual，状态-动作 head 再将其写回 Q-memory。精确恒等式使用外部提供、输入相关的等值路由 mask，以及外部 visited-query/null-token gate，并恢复同步的逐对均值表格 SARSA 更新。移除 equality mask 后得到有限 logit、gate-assisted 的近似，我们分别控制 retrieval leakage 与 write-back leakage。将单例构造与由当前动作价值导出的策略结合，便形成通常的顺序同策略控制闭环。第二种构造进一步加入动作注意力阶段。它在有限温度下的目标，恰好是当前 Boltzmann 策略的条件 Expected-SARSA 目标，同时也近似贪心动作选择。对于动作尖锐度 β ，有

$$0 \leq \max_a Q(s, a) - \sum_a \text{softmax}(\beta Q(s, \cdot))_a Q(s, a) \leq \log(|A|)/\beta.$$

将该界与 Bellman 最优算子的压缩性结合，可为理想表格情形下的近似贪心更新给出显式的邻域保证。Q-retrieval leakage、residual write-back leakage 和有限上下文误差作为彼此分离的扰动项进入分析。这些保证强化了采样 SARSA 的策略改进路径，但并非后者成立所必需。

一个可执行的 literal matrix witness 对完整 prompt、所有投影与 mask、residual 状态和 write-back 进行验证，并同时对照紧凑实现与表格参考。与此分开，受控表格实验用紧凑算子评估策略行为；大规模 sampled-control sweep 直接索引两个 Q 值，并没有执行完整 prompt 网络。在 30 个采样控制任务上，该紧凑闭环使精确平均策略回报提高 0.429，并在 30/30 个任务上取得正的最终 J_μ 增益，同时紧密跟踪共享轨迹的精确匹配比较器。双阶段算子在 20/20 个期望更新任务上取得正的最终 J_μ 增益，并随动作注意力变得更尖锐而趋近精确贪心控制。结果建立的是 oracle-routed、固定权重 softmax 注意力对表格动作价值控制的实现；我们不声称模型学会路由、具有逐状态支配性，或每次随机更新都单调改进策略。

1. 引言

标准的归一化 softmax 注意力能否在上下文内支持策略改进？固定权重的 Transformer 可以在前向传播中执行学习算法 [1–3]，近期研究也给出了强化学习中的构造性例子。Liang 和 Lai [4] 证明，线性注意力可以实现参数化半梯度 SARSA 与 actor-critic 更新。Xie 等人 [5] 证明，标准 softmax 注意力可以针对固定策略实现加权 TD 策略评估。这两条研究路线合在一起，仍留下一个问题：后一种归一化注意力机制能否不只做策略评估，还能支持动作价值控制？

策略改进并不要求每个 TD 目标中都包含最大值。SARSA 使用当前行为策略实际选出的动作 a'_k ，构造同策略残差

$$\delta_k^S = r_k + \gamma Q(s'_k, a'_k) - Q(s_k, a_k).$$

先更新 Q ，再由更新后的价值导出下一轮行为策略，就得到一个同策略控制闭环 [6]。贪心 Bellman 备份是另一条更强的路径：它通过 $\max_b Q(s', b)$ 将动作选择置于目标内部。这两条路径回答的是互补问题，不应混为一谈。

我们用一个持久化 Q-memory token 表示每个状态-动作对 $x = (s, a)$ ，其中存储 $Q(x)$ ；原始 transition token 则包含当前与下一 pair 标识以及 reward。两个固定的结构化路由 head 检索 sampled SARSA 所需的两个 Q 值，逐位置映射形成带符号 residual，最后的标准 softmax head 执行标量写回。这种 token 化方式无需通过样本相关的 δ 与 ϕ 的乘积来更新全局参数向量。统一的写回算子为

$$Q^+(x) = Q(x) + \alpha \sum_k K_\eta(x_k, x) \delta_k,$$

其中， K_η 是归一化的状态-动作匹配核，带符号的 TD 残差由 value 向量携带。因此，注意力权重为正并不会消除负的 TD 修正。

第一种构造并不把 sampled SARSA residual 当作输入，而是证明完整 raw-token computation。精确模型是一个采用标准指数 softmax、双向结构化注意力、无 LayerNorm 与 dropout 的双 block residual attention-FFN 网络；它不是 decoder-only 因果 Transformer。外部提供、输入相关的 equality-routing mask 检索 $Q(s, a)$ 与 $Q(s', a')$ ，固定的两单元 ReLU 映射形成 residual，外部 visited-query/null-token gate 完成同步逐对均值写回。单例版本生成通常的顺序 SARSA iterates。移除 equality mask 后，有限 logit 近似 retrieval 与 write-back，但仍保留外部 gate。

第二种构造增加一个动作注意力阶段。对当前 Boltzmann 策略

$$p_\beta(b | s) = \frac{\exp(\beta Q(s, b))}{\sum_c \exp(\beta Q(s, c))},$$

该阶段返回

$$M_\beta Q(s) = \sum_b p_\beta(b | s) Q(s, b).$$

在有限 β 下，这恰好是当前 Boltzmann 策略的条件 Expected-SARSA 目标。它同时近似贪心动作选择，并满足一致界

$$0 \leq \max_b Q(s, b) - M_\beta Q(s) \leq \log(|A|)/\beta.$$

Expected-SARSA 与近似贪心这两种解释都成立。我们仅用第二种解释推导更强的最优控制结论：在理想的表格、同步设定中，所得更新是松弛 Bellman 最优更新的有界扰动。证明使用 T^* 的压缩性，而不假设尚未证明的平滑算子压缩性。核失配与有限上下文误差作为彼此独立的扰动进入分析。

受控的表格实验通过策略行为检验两条控制路径。为扩大 sweep，采样 SARSA 实验用直接表索引给出两个 Q 值，softmax 只实现 write-back kernel；因此它运行的是紧凑算子，而非 literal prompt 网络。我们将其与共享轨迹的精确匹配写回比较器对照，从而单独考察有限 softmax matching，而不把比较器误称为独立的同策略学习器。另一个 literal matrix witness 单独检验完整 prompt 构造。对于双阶段紧凑算子，我们在改变动作尖锐度和核尖锐度的同时，将其与精确贪心控制比较。

本文的贡献如下：

1. 给出一个端到端、固定权重的标准 softmax 构造，从 Q-memory token 中检索当前动作价值、形成 sampled-SARSA residual 并写回；同时区分 externally routed 的精确恒等式与 equality-mask-free but gate-assisted 的有限 logit 近似。
2. 证明双阶段构造的有限温度目标恰好是 Boltzmann Expected SARSA，同时也是对贪心动作选择的一致有界近似。
3. 针对更强的近似贪心路径，推导动作价值保证与策略性能保证，并显式分离动作尖锐度、核误差和有限上下文误差。
4. 通过配对控制实验和策略回报评估两条路径。

本文结果是构造性的，并且有意限定适用范围。精确 content selection 使用外部提供、输入相关的结构化等值 mask 与外部 visited-query/null-token gate；有限 equality-mask-free logit 仍为 gate-assisted 近似。环境交互、精确 ε -greedy argmax 与随机动作采样均在网络之外。我们不声称每个随机 TD 步骤都会单调改进策略，不声称通用预训练 Transformer 会自动学会这些算子或路由，也不声称主 control sweep 执行完整 token 网络。主要保证针对具有显式覆盖条件的有限表格问题。

2. 相关工作

作为上下文内算法的 Transformer。线性注意力和自注意力构造已被用于联系梯度下降、岭回归以及其他可在一次前向传播中执行的学习算法 [1–3]。这种构造性视角促使我们追问：固定注意力机制能够表示哪些强化学习控制操作？

构造性上下文内强化学习。Liang 和 Lai [4] 给出了与策略改进最接近的结果。他们的线性注意力构造通过半梯度 SARSA 项更新全局参数向量，其 actor-critic 构造则提供第二条同策略路径。Xie 等人 [5] 使用标准归一化 softmax 注意力，为固定 Markov 奖励过程实现非参数 TD 策略评估。我们的状态-动作 token 构造沿用了 [5] 的带符号 softmax 写回机制，但将其接入动作价值控制。它与 [4] 在注意力类型和表示方式上都不同：归一化 softmax 直接更新 Q token，而线性注意力构造出更新全局权重向量所需的参数化半梯度乘积。

SARSA、Expected SARSA 与贪心控制。当动作价值更新与由当前估计导出的行为策略相结合时，经典 SARSA 是一种同策略控制方法 [6]。Expected SARSA 将采样得到的下一动作价值替换为其在目标策略下的条件期望。对于由当前 Q 值诱导的 Boltzmann 策略，这个条件期望恰好就是我们的双阶段算子所使用的 softmax 加权动作价值。策略改进并不要求使用贪心 Bellman 控制，但后者提供一条直接通向 Q^* 的路径以及策略性能界。因此，我们将采样 SARSA 与近似贪心化视为互补的 softmax 控制构造。

归一化与动作选择。归一化 softmax 注意力头返回其 value 向量的凸组合 [7]。这不会消除 value 中已经携带的带符号坐标，因此 softmax 核可以聚合正、负 TD 残差。当注意力被用于在动作之间选择时，归一化确实会带来可量化的尖锐度权衡。在我们的近似贪心路径中，动作被视为候选项，因此 Velickovic 等人 [8] 关于候选项数量与尖锐度的分析与本文相关。

范围。本文贡献是在算子层面证明标准 softmax 注意力能够实现策略改进。我们既不复现线性注意力的训练动力学，也不声称预训练模型必然会发现该构造。采样 SARSA 路径建立直接的同策略机制；双阶段路径则通过在前向算子内部加入近似贪心化来强化这一结果。

3. 端到端构造与保证

3.1 精确模型类别与完整 prompt

令 $\mathcal{X} = \mathcal{S} \times \mathcal{A}$, $m = |\mathcal{X}|$, 并固定 $\mathcal{X}$ 的枚举。状态-动作对 x 的独热标识为 $e_x \in \mathbb{R}^m$ 。一次更新接收冻结的表 Q_l 、固定标量 $\gamma \in [0, 1)$ 与 $\alpha > 0$, 以及 N 条采样转移

$$(S_k, A_k, R_k, S'_k, A'_k), \quad k = 1, \dots, N,$$

其中 A'_k 是当前行为策略实际选择的下一动作。记 $X_k = (S_k, A_k)$ 、 $X'_k = (S'_k, A'_k)$, 以及 $n_x = \sum_{k=1}^N \mathbf{1}\{X_k = x\}$ 。

我们针对一个精确定义的 residual attention 网络证明结论。它包含两个 attention-FFN block, 采用标准指数 softmax, 不含 LayerNorm 和 dropout。token 按列排列。网络使用双向结构化注意力, 不是 decoder-only 因果 Transformer。投影矩阵在固定 m, N, γ, α 后即固定。结构化等值路由掩码由外部提供并且是输入相关的; 另一个外部支持门控依据离散 pair 标识提供已访问查询 (visited query) / null token 规则。因此, 该定理给出的是 oracle-routed 的精确参考构造, 并不证明或声称通用预训练 Transformer 会学习或发现路由。

取 token 宽度 $d = 2m + 8$, 使用直和坐标约定

$$\mathbb{R}^d = \underbrace{\mathbb{R}^3}_{\text{type}} \oplus \underbrace{\mathbb{R}^m}_{\text{current ID}} \oplus \underbrace{\mathbb{R}^m}_{\text{next ID}} \oplus \underbrace{\mathbb{R}^5}_{(r, q, u, v, \delta)}.$$

令 $\tau_Q, \tau_T, \tau_Z \in \mathbb{R}^3$ 为三个 type 基向量。五个标量坐标依次存 reward r 、持久化 memory 值 q 、检索到的当前值 u 、检索到的下一值 v 和 TD residual δ 。定义

$$\begin{aligned} M_x &= (\tau_Q, e_x, 0_m, 0, Q_l(x), 0, 0, 0)^\top, \\ T_k &= (\tau_T, e_{X_k}, e_{X'_k}, R_k, 0, 0, 0, 0)^\top, \\ Z &= (\tau_Z, 0_m, 0_m, 0, 0, 0, 0, 0)^\top, \\ H^{(0)} &= [M_{x_1}, \dots, M_{x_m}, T_1, \dots, T_N, Z] \in \mathbb{R}^{d \times L}, \quad L = m + N + 1. \end{aligned} \tag{3.1}$$

null token Z 并非零向量, 因为它保留 type 坐标; 但下文所有作为 attention value 读取的坐标均为零。特别地, 原始 transition token 既不包含 $Q_l(X_k)$ 、 $Q_l(X'_k)$, 也不包含预计算 residual。

令 $P_c, P_n \in \mathbb{R}^{m \times d}$ 分别选取 current-ID 和 next-ID block。令 $\mathbf{e}_r, \mathbf{e}_q, \mathbf{e}_u, \mathbf{e}_v, \mathbf{e}_\delta \in \mathbb{R}^d$ 为五个标量坐标的基列。对满足 $W_Q, W_K \in \mathbb{R}^{d_h \times d}$ 、 $W_V \in \mathbb{R}^{d_v \times d}$ 、 $W_O \in \mathbb{R}^{d \times d_v}$ 的 head, 采用 query-by-source 权重

$$A_{ij} = \frac{\exp((W_Q h_i)^\top (W_K h_j) / \sqrt{d_h} + \mathcal{M}_{ij})}{\sum_{s=1}^L \exp((W_Q h_i)^\top (W_K h_s) / \sqrt{d_h} + \mathcal{M}_{is})}.$$

矩阵形式的 head 输出为 $W_O(W_V H)A^\top \in \mathbb{R}^{d \times L}$ 。以下每个 mask row 都有非空支持; 非目标 query 被路由到 Z , 因此不存在全为 $-\infty$ 的 softmax row。

定理 3.1 (结构化等值路由下的精确 sampled-SARSA)。 对固定的 m, N, γ, α , 以及下文外部给定的等值路由 mask 和 visited/null 支持规则, 两 block residual attention-FFN 网络把 (3.1) 中的原始 prompt 映射成满足下式的

Q-memory: 对每个 $x \in \mathcal{X}$,

$$Q_{l+1}(x) = \begin{cases} Q_l(x) + \frac{\alpha}{n_x} \sum_{k: X_k=x} [R_k + \gamma Q_l(X'_k) - Q_l(X_k)], & n_x > 0, \\ Q_l(x), & n_x = 0. \end{cases}$$

3.2 定理 3.1 的证明: 检索与 residual 构造

步骤 1: 当前 pair 检索。 第一个 head 取

$$\begin{aligned} W_Q^{\text{cur}} &= P_c, & W_K^{\text{cur}} &= P_c, & W_V^{\text{cur}} &= \mathbf{e}_q^\top, & W_O^{\text{cur}} &= \mathbf{e}_u, \\ \mathcal{M}_{ij}^{\text{cur}} &= 0 & \Leftrightarrow & (i = T_k, j = M_{X_k}) \text{ or } (i \notin \{T_1, \dots, T_N\}, j = Z). \end{aligned} \quad (3.2)$$

其余 mask 元素均为 $-\infty$ 。对 transition query T_k , 唯一允许的 source 是 M_{X_k} , 所以无论数值 logit 为何, 该 softmax row 都只在这一位置取权重 1, 并且

$$W_O^{\text{cur}} \sum_j A_{T_k j}^{\text{cur}} W_V^{\text{cur}} h_j = \mathbf{e}_u \mathbf{e}_q^\top M_{X_k} = Q_l(X_k) \mathbf{e}_u.$$

Q-memory 或 null query 只允许读取 Z ; 由于 $\mathbf{e}_q^\top Z = 0$, 其 head 输出为零。

步骤 2: 下一 pair 检索。 第二个 head 与第一个并行, 只在 query 侧读取 next-ID block:

$$\begin{aligned} W_Q^{\text{next}} &= P_n, & W_K^{\text{next}} &= P_c, & W_V^{\text{next}} &= \mathbf{e}_q^\top, & W_O^{\text{next}} &= \mathbf{e}_v, \\ \mathcal{M}_{ij}^{\text{next}} &= 0 & \Leftrightarrow & (i = T_k, j = M_{X'_k}) \text{ or } (i \notin \{T_1, \dots, T_N\}, j = Z), \\ W_O^{\text{next}} &\sum_j A_{T_k j}^{\text{next}} W_V^{\text{next}} h_j = Q_l(X'_k) \mathbf{e}_v. \end{aligned} \quad (3.3)$$

未列出的元素仍为 $-\infty$, 每个非 transition query 的 head 输出仍为零。两个 head 都读取同一 $H^{(0)}$, 符合并行 multi-head attention; 它们的输出投影写入互不相交的坐标。因此 attention residual 后的状态为

$$\begin{aligned} H^{(a)} &= H^{(0)} + O^{\text{cur}} + O^{\text{next}}, \\ M_x^{(a)} &= M_x, & Z^{(a)} &= Z, \\ T_k^{(a)} &= (\tau_T, e_{X_k}, e_{X'_k}, R_k, 0, Q_l(X_k), Q_l(X'_k), 0)^\top. \end{aligned}$$

步骤 3: 精确的逐位置 residual 映射。 令

$$\begin{aligned} g^\top &= \mathbf{e}_r^\top + \gamma \mathbf{e}_v^\top - \mathbf{e}_u^\top, & W_1 &= \begin{bmatrix} g^\top \\ -g^\top \end{bmatrix} \in \mathbb{R}^{2 \times d}, \\ W_2 &= \mathbf{e}_\delta \begin{bmatrix} 1 & -1 \end{bmatrix} \in \mathbb{R}^{d \times 2}, & W_2 \text{ReLU}(W_1 h) &= \mathbf{e}_\delta g^\top h. \end{aligned} \quad (3.4)$$

最后一个恒等式来自 $\text{ReLU}(z) - \text{ReLU}(-z) = z$ 。所以第一 block 的 FFN residual 得到

$$H^{(1)} = H^{(a)} + W_2 \text{ReLU}(W_1 H^{(a)}), \quad \delta_k^S = R_k + \gamma Q_l(X'_k) - Q_l(X_k).$$

对 Q-memory 与 null token, r, u, v 坐标均为零, 所以 FFN 输出为零。Block I 保留全部标识、reward 和 Q-memory 值, 只把两个检索值与带符号的 sampled-SARSA residual 写入各 transition token。

3.3 定理 3.1 的证明：写回与组装

步骤 4：完整 write-back head。 第二个 block 只有一个 active head:

$$\begin{aligned} W_Q^{\text{wr}} &= P_c, & W_K^{\text{wr}} &= P_c, & W_V^{\text{wr}} &= \mathbf{e}_\delta^\top, & W_O^{\text{wr}} &= \alpha \mathbf{e}_q, \\ \mathcal{M}_{ij}^{\text{wr}} &= 0 \Leftrightarrow \begin{cases} i = M_x, j = T_k, X_k = x, & n_x > 0, \\ i = M_x, j = Z, & n_x = 0, \\ i \in \{T_1, \dots, T_N, Z\}, j = Z. \end{cases} \end{aligned} \quad (3.5)$$

所有其余元素都是 $-\infty$ 。对已访问 memory query M_x 以及任意允许的 source T_k ,

$$\frac{(P_c M_x)^\top (P_c T_k)}{\sqrt{m}} = \frac{e_x^\top e_{X_k}}{\sqrt{m}} = \frac{1}{\sqrt{m}}.$$

因此, n_x 个允许 logit 相等, 每个权重恰为 $1/n_x$ 。value 投影选取带符号标量 δ_k^S , 故 M_x 的 head 输出是

$$\frac{\alpha}{n_x} \sum_{k: X_k = x} \delta_k^S \mathbf{e}_q.$$

正的 softmax 权重不会消除负 TD correction, 因为符号位于 value 坐标而非注意力权重中。若 $n_x = 0$, 唯一 source 是 Z , 且 $\mathbf{e}_\delta^\top Z = 0$, 所以输出为零。transition 和 null query 同样只读取 Z , 保持不变。

步骤 5：组装两个 block。 将全部未使用的投影 block 置零, 并把第二 block 的 FFN 置零。相对于 (3.1) 的初始状态, 完整 token-state 变化为

token	Block I attention 后	Block I FFN 后	Block II 后
M_x	不变	不变	置 $q = Q_{l+1}(x)$
T_k	置 $u = Q_l(X_k)$ 、 $v = Q_l(X'_k)$	置 $\delta = \delta_k^S$	不变
Z	不变	不变	不变

表中未列出的每个坐标都与 $H^{(0)}$ 完全相同。

读取 $H^{(2)}$ 的 Q-memory 坐标可得

$$Q_{l+1}(x) = \begin{cases} Q_l(x) + \frac{\alpha}{n_x} \sum_{k: X_k=x} [R_k + \gamma Q_l(X'_k) - Q_l(X_k)], & n_x > 0, \\ Q_l(x), & n_x = 0. \end{cases} \quad (3.6)$$

这正是定理陈述。每个展示出的矩阵，对声明的 m, N, γ, α 而言都是固定坐标 selector 或固定标量倍数；全部数据依赖只存在于 prompt 与外部给定 mask 中。因此，两次 Q 检索、residual 构造与 Q 写回都包含在这两个 block 的计算内。□

精确恒等式的范围。 (3.6) 是冻结 Q_l 下的逐对均值 (per-pair mean) 更新，不是全局 batch convention

$$Q_l(x) + \frac{\alpha}{N} \sum_{k: X_k=x} \delta_k^S,$$

也不会在一个冻结 batch 内按顺序处理同一 pair 的重复出现。单例调用满足 $n_x = 1$ ，才恢复通常的顺序表格 SARSA 步。构造需要输入相关的等值路由与外部 visited/null 支持检测；二者都不是 softmax 学出的因果 mask，也不表明通用预训练 Transformer 会发现该布局。精确网络固定于给定的 m, N, γ, α ；可变 Robbins–Monro 步长要求对应的输出投影模块族，或额外的乘法机制。每个控制 round 都重建 prompt，等价地清空并重新初始化 u, v, δ scratch 坐标。第 3.8 节在有限 logit 下移除 equality mask，但仍保留 visited-query gate。

3.4 从更新算子到控制

推论 3.2 (顺序 SARSA 等价)。 若每个控制 round 只处理一条采样转移，并且只有其已访问 pair 发出非 null write-back query，则以步长 α_t 实例化的构造产生

$$Q_{t+1}(S_t, A_t) = Q_t(S_t, A_t) + \alpha_t [R_{t+1} + \gamma Q_t(S_{t+1}, A_{t+1}) - Q_t(S_t, A_t)],$$

其余状态–动作值均不变。因此，固定输出 scale 依次为给定 α_t 的一系列 block，精确生成表格型顺序 sampled-SARSA iterates；单个固定 block 只对应常数步长。

对奖励有界的有限表格 MDP，在每个状态–动作对被无限访问、采用逐 pair Robbins–Monro 步长以及无限探索且极限贪心 (GLIE) 的策略序列时，顺序构造继承经典的几乎必然收敛结论 [6]。第 5.2 节的冻结 mini-batch 实验采用不同的更新 convention 与固定探索率，因此不对该实验 protocol 声称这一收敛定理。

单个 SARSA residual 并不是策略改进定理。通常的精确策略改进桥梁在逻辑上是分开的。若 π 是 ε -soft 策略、 Q^π 已被精确评估，且 π' 关于 Q^π 为 ε -贪心策略，则写成 $\pi = \varepsilon/|\mathcal{A}| + (1 - \varepsilon)\tilde{\pi}$ 有

$$\sum_a \pi'(a|s) Q^\pi(s, a) = \frac{\varepsilon}{|\mathcal{A}|} \sum_a Q^\pi(s, a) + (1 - \varepsilon) \max_a Q^\pi(s, a) \geq V^\pi(s).$$

因此策略改进定理给出 $V^{\pi'} \geq V^\pi$ 。若估计 $\hat{Q}$ 满足 $\|\hat{Q} - Q^\pi\|_\infty \leq \xi$ ，最坏情形结论弱化为 $V^{\pi'} \geq V^\pi - 2\xi/(1 - \gamma)$ ；单调性需要足够的 advantage margin。定理 3.1 建立表示等价，推论 3.2 给出有条件的在线收敛路径，而冻结 batch 实验提供经验性的 before–after 策略证据；这是三类不同结论。

3.5 内部 Boltzmann 动作注意力

对 $\beta > 0$, 定义当前 Boltzmann 策略及其动作价值期望:

$$p_\beta(b | s; Q) = \frac{\exp(\beta Q(s, b))}{\sum_c \exp(\beta Q(s, c))},$$

$$M_\beta Q(s) = \sum_b p_\beta(b | s; Q) Q(s, b).$$

相应的条件 Bellman 目标为

$$(T_\beta Q)(s, a) = \mathbb{E} [R + \gamma M_\beta Q(S') | s, a].$$

命题 3.3 (Expected-SARSA 恒等式)。若在给定 S' 时, A' 从 $p_\beta(\cdot | S'; Q)$ 中采样, 则

$$\mathbb{E} [R + \gamma Q(S', A') | s, a] = (T_\beta Q)(s, a).$$

证明。首先对 S' 条件化。关于 A' 的内层期望为 $\sum_b p_\beta(b | S'; Q) Q(S', b) = M_\beta Q(S')$ 。再取剩余的条件期望即可证明该恒等式。

因此, 在有限 β 下, T_β 恰好是与当前 Q 绑定的策略之条件 Expected-SARSA 算子。由于 β 增大时 M_β 趋近最大值, 同一算子也可以作为近似贪心化来分析。这两种解释相互补充; 有限 β 并不是精确 Q-learning。

3.6 Softmax 对贪心动作选择的近似

引理 3.4 (softmax 动作聚合的熵界)。对任意 $q \in \mathbb{R}^d$ 与 $\beta > 0$, 有

$$0 \leq \max_a q_a - \sum_a \text{softmax}(\beta q)_a q_a \leq \frac{\log d}{\beta}.$$

证明。令 $p = \text{softmax}(\beta q)$, 并定义

$$\text{LSE}_\beta(q) = \beta^{-1} \log \sum_a \exp(\beta q_a).$$

Gibbs 熵恒等式给出 $\text{LSE}_\beta(q) = \sum_a p_a q_a + H(p)/\beta$ 。又因为 $\max_a q_a \leq \text{LSE}_\beta(q)$ 、 $\sum_a p_a q_a \leq \max_a q_a$ 且 $0 \leq H(p) \leq \log d$, 结论成立。□

推论 3.5 (贪心目标偏差)。对任意 Q , 有

$$\|T_\beta Q - T^* Q\|_\infty \leq \gamma \frac{\log(|A|)}{\beta}.$$

3.7 近似贪心路径的更强保证

考虑采用精确状态-动作匹配、具有完全覆盖的同步更新

$$Q_{\ell+1} = (1 - \alpha)Q_\ell + \alpha T_\beta Q_\ell,$$

其中 $0 < \alpha \leq 1$, 并定义 $\rho = 1 - \alpha(1 - \gamma)$ 。

定理 3.6 (Bellman 最优性的有界扰动)。 迭代满足

$$\|Q_{\ell+1} - Q^*\|_\infty \leq \rho \|Q_\ell - Q^*\|_\infty + \alpha\gamma \frac{\log(|A|)}{\beta}.$$

从而

$$\limsup_{\ell \rightarrow \infty} \|Q_\ell - Q^*\|_\infty \leq \frac{\gamma \log(|A|)}{\beta(1 - \gamma)}.$$

证明。 加上再减去 T^*Q_ℓ 。松弛恒等映射贡献 $1 - \alpha$, T^* 的压缩性贡献 $\alpha\gamma$, 推论 3.5 则贡献加性目标偏差。迭代所得的标量递推关系, 即得上述上极限界。该证明不假设 T_β 本身是压缩映射。□

若 β_ℓ 随深度趋于无穷, 则加性项趋于零, 同一稳定标量递推关系给出对 Q^* 的收敛。固定 β 时, 所得结果是一个受控邻域, 而非精确收敛。

3.8 无等值掩码的有限 logit 偏差

精确定理把 pair equality 委托给 mask。现在移除两个 retrieval mask 与 write-back equality mask, 但保留外部 visited-query gate。因此, 所得构造是 equality-mask-free 但仍 gate-assisted。

对 retrieval sharpness $\zeta > 0$, 缩放独热投影, 使正确 Q-memory logit 为 ζ 、每个错误 logit 为零, 并在全部 m 个 Q-memory token 上取 softmax。正确质量、总 off-target 质量以及 induced residual error 满足

$$\begin{aligned} p_\zeta &= \frac{e^\zeta}{e^\zeta + m - 1}, & \lambda_R &= 1 - p_\zeta = \frac{m - 1}{e^\zeta + m - 1}, \\ |\tilde{Q}_l(x) - Q_l(x)| &\leq \lambda_R \text{span}(Q_l), \\ |\tilde{\delta}_k^S - \delta_k^S| &\leq (1 + \gamma)\lambda_R \text{span}(Q_l) =: E_R. \end{aligned} \tag{3.7}$$

其中 $\text{span}(Q_l) = \max_x Q_l(x) - \min_x Q_l(x)$ 。第一个 value bound 来自: 质量 λ_R 从正确表项移到与其相差不超过 table span 的值; residual 包含一次 current retrieval 与一次折扣后的 next retrieval, 所以产生因子 $1 + \gamma$ 。

对 write-back sharpness $\eta > 0$, 使用 logit $\eta \langle e_{x_k}, e_x \rangle$ 。对已访问 query x , 有限 attention kernel 与精确 group-mean kernel 为

$$\begin{aligned}
K_\eta(k|x) &= \frac{\exp(\eta \mathbf{1}\{X_k = x\})}{n_x e^\eta + N - n_x}, & U(k|x) &= \frac{\mathbf{1}\{X_k = x\}}{n_x}, \\
\varepsilon_W(x) &:= \sum_{k=1}^N |K_\eta(k|x) - U(k|x)| = \frac{2(N - n_x)}{n_x e^\eta + N - n_x}.
\end{aligned} \tag{3.8}$$

最后一个恒等式中, matching token 的总绝对差与 nonmatching token 的总质量都等于 $(N - n_x)/(n_x e^\eta + N - n_x)$ 。

命题 3.7 (有限 logit 端到端更新误差)。 假设每条转移都满足 $|\delta_k^S| \leq B$ 。对每个已访问 query,

$$|Q_{l+1}^{\text{soft}}(x) - Q_{l+1}^{\text{exact}}(x)| \leq \alpha[E_R + B\varepsilon_W(x)]. \tag{3.9}$$

证明。 有限更新为 $\alpha \sum_k K_\eta(k|x) \tilde{\delta}_k^S$, 精确更新为 $\alpha \sum_k U(k|x) \delta_k^S$ 。加上并减去 $\alpha \sum_k K_\eta(k|x) \delta_k^S$ 。由于 $K_\eta(\cdot|x)$ 是概率向量, (3.7) 将 residual replacement term 控制在 αE_R ; 由 $|\delta_k^S| \leq B$, (3.8) 将 kernel replacement term 控制在 $\alpha B\varepsilon_W(x)$ 。两项相加得到 (3.9)。□

对冻结的策略和冻结的 Q , 定义有限上下文残差偏差

$$\varepsilon_D = \max_{x: n_x > 0} \left| \frac{1}{n_x} \sum_{k: X_k = x} \delta_k^S - [(T^\pi Q_l)(x) - Q_l(x)] \right|.$$

实现的更新与相应已访问 population update 的差异至多为 $\alpha(E_R + B\varepsilon_W + \varepsilon_D)$ 。在 approximate-greedy full-coverage recurrence 中, 这些项以加性方式进入:

$$\|Q_{\ell+1} - Q^*\|_\infty \leq \rho \|Q_\ell - Q^*\|_\infty + \alpha \left[\frac{\gamma \log |\mathcal{A}|}{\beta} + E_R + B\varepsilon_W + \varepsilon_D \right].$$

这是一个单步算子偏差结论。它不会把任意有限轨迹变成全局 Bellman recurrence, 也不会没有独立采样、mixing 或 martingale 假设时自动给出 concentration rate。retrieval sharpness、write-back sharpness 与 action sharpness 控制三种不同操作。

3.9 策略层面的结论

推论 3.8。 若 $\|Q - Q^*\|_\infty \leq \varepsilon$, 且 π_Q 关于 Q 为贪心策略, 则

$$\|V^* - V^{\pi_Q}\|_\infty \leq \frac{2\varepsilon}{1 - \gamma}.$$

因此, 近似贪心动作价值保证可推出一个有条件的策略性能保证。采样 SARSA 路径则分别从定理 3.1 获得精确算子等价、从推论 3.2 获得有条件的渐近结论, 并在独立的冻结 batch protocol 下提供经验性的最终 return 证据。

4. 方法

4.1 端到端构造与紧凑实验算子

第3节在 literal $d \times L$ prompt 上给出完整 token computation。原始 transition token 只包含 pair 标识与 reward；两个 structured-routing retrieval head 从 Q-memory 复制所需的当前 Q 值；显式的两单元 ReLU FFN 形成带符号 TD residual；最终 state-action head 执行 write-back。所有 $W_Q, W_K, W_V, W_O, W_1, W_2$ 都是固定坐标映射，初始 transition token 中不提供 residual 或当前 Q 值。

为提高效率，大规模 control sweep 绕过两个 prompt-level retrieval head：直接 table indexing 给出同样的两个标量，同一固定线性表达式形成 residual，标准 softmax kernel 执行 write-back。因此，该 sweep 检验的是紧凑 write-back/control operator，而不是完整 prompt 网络的执行。独立的 literal matrix witness 则实例化完整 prompt、每个投影、所有 query-by-source routing mask、null-token gate、residual scratch state 与 write-back head，并把结果同时与紧凑实现和表格参考比较。实验使用独热状态-动作标识，因此两条实现都不检验 learned representation 或 function approximation。

对已访问查询 x ，标准点积 softmax 注意力使用

$$K_\eta(k | x) = \frac{\exp(\eta \langle \psi(X_k), \psi(x) \rangle)}{\sum_j \exp(\eta \langle \psi(X_j), \psi(x) \rangle)},$$

并执行写回

$$Q_{\ell+1}(x) = Q_\ell(x) + \alpha_\ell \sum_k K_\eta(k | x) \delta_k.$$

注意力权重为正且经过归一化，但 δ_k 带符号，因此负的 TD 修正仍然可用。上下文中未出现的查询不更新。定理 3.1 的精确构造使用外部提供的 equality-routing mask，并通过外部 gate 将未访问查询路由到零值 null token。移除 equality mask 后，有限 η 给出第 3.8 节与 finite-logit Q retrieval 联合分析的显式近似；该近似仍保留 visited-query gate。

4.2 路径 I：采样 SARSA 控制

对每个批次，在 S'_k 处从当前行为策略中采样 A'_k ，并令

$$\delta_k^S = R_k + \gamma Q_\ell(S'_k, A'_k) - Q_\ell(X_k).$$

第3节的两个 retrieval head 与固定 residual map 构造 δ_k^S ，state-action head 执行上述写回。在精确匹配下，这恰好是

$$Q_{\ell+1}(x) = Q_\ell(x) + \frac{\alpha_\ell}{n_x} \sum_{k: X_k=x} \delta_k^S,$$

即在冻结 Q_ℓ 下，同步、按状态-动作对取均值的小批量 SARSA 更新。当只查询单个转移时，它就是通常的采样 SARSA 更新。它既不是对重复访问求和的更新，也不是在批次内部不断改变 Q 的顺序更新。

为了闭合控制回路，下一轮行为策略由 $Q_{\ell+1}$ 导出。在采样实验中，我们采用 ε -贪心策略。TD 目标本身不包含最大值：下一动作就是从当前策略实际采样的动作。在定理与 literal witness 中，Q retrieval、residual formation 和 write-back 都发生在构造的 block 内；大规模 control sweep 则用直接 table indexing 取代 retrieval，只运行紧凑 residual/write-back kernel。环境交互、精确 ε -greedy argmax 与随机动作采样均为外部接口。定理 3.1 是 operator identity，推论 3.2 讨论不同的 singleton online protocol，而当前 frozen-batch protocol 只接受经验评估。

4.3 路径 II: Boltzmann Expected SARSA 与近似贪心化

更强的路径在每个下一状态的动作 token 上增加一个标准 softmax 注意力头。其得分为 $\beta Q_\ell(S'_k, b)$ ，value 为 $Q_\ell(S'_k, b)$ ，分组掩码将注意力限制在共享同一 S'_k 的动作上。输出为

$$M_\beta Q_\ell(S'_k) = \sum_b \frac{\exp(\beta Q_\ell(S'_k, b))}{\sum_c \exp(\beta Q_\ell(S'_k, c))} Q_\ell(S'_k, b).$$

随后，一个线性投影构造

$$\delta_k^\beta = R_k + \gamma M_\beta Q_\ell(S'_k) - Q_\ell(X_k),$$

统一的状态-动作注意力头再将残差写回 Q token。提出的算子内部没有使用精确最大值。在有限 β 下，该目标是当前 Boltzmann 策略的条件 Expected-SARSA 目标。若将其视为贪心控制的近似，则其 Bellman 目标层面的误差由 $\gamma \log(|A|)/\beta$ 控制，从而得到定理 3.6。

4.4 构造的适用范围

精确 sampled-SARSA 结论针对一个标准指数归一化、固定坐标投影、双向结构化注意力、无 LayerNorm 与 dropout 的双 block residual attention-FFN 网络；它不是 decoder-only 因果 Transformer。矩阵固定于给定 m, N, γ, α 。构造从原始 transition 与持久化 Q-memory 出发，不假设预计算 TD residual。精确 retrieval 与 write-back 依赖外部提供、输入相关的 equality-routing mask 和外部 visited-query/null-token gate；命题 3.7 移除 equality mask，但保留该 gate。我们不声称通用预训练 Transformer 会发现布局或学会路由，不声称有限 logit 实现精确 content selection，也不把 simulator action execution 与随机采样放入确定性 attention head。可变步长 schedule 需要输出 scale 不同的 block family，或额外乘法机制。

5. 实验

5.1 问题、环境与策略指标

实验围绕与核心主张直接相关的三个问题展开：

1. 紧凑的单阶段 softmax write-back 算子是否与 sampled-SARSA 参考一致，独立的 literal witness 是否又与该紧凑算子一致？
2. 将该算子与其行为策略闭合后，是否能提高策略回报？
3. 当双阶段算子的内部动作聚合趋近贪心控制时，它是否仍保持策略改进？

每个任务都是一个有限随机 MDP。转移概率的每一行和初始状态分布均从对称 Dirichlet 分布中采样，转移奖励在 $[-1, 1]$ 上均匀分布。对于策略 π 和初始分布 μ ，我们精确计算折扣回报

$$J_{\mu}(\pi) = \mu^{\top} (I - \gamma P_{\pi})^{-1} r_{\pi},$$

因此，策略比较不包含 rollout 评估噪声。除非另有说明，文中报告的离散程度均为独立采样任务之间的样本标准差。

5.2 采样 SARSA：匹配写回与闭环改进

我们使用 30 个 MDP，每个包含 9 个状态、4 个动作，且 $\gamma = 0.5$ 。标准 softmax 学习器从一个较小的随机 Q 表出发，采用由当前 Q 导出的 $\varepsilon = 0.1$ 贪心行为策略。在 200 次控制更新中的每一次，它都生成一条包含 128 个转移的轨迹，冻结该批次的 Q 与策略，并以 $\eta = 12$ 和下列步长执行按状态-动作对取均值的采样 SARSA 更新：

$$\alpha_{\ell} = \frac{0.35}{\sqrt{1 + 0.02(\ell - 1)}}.$$

匹配参考实现接收相同的转移和步长，但使用精确匹配核 U 。它用于分离有限 softmax 匹配的影响，并不是第二个独立采样的控制运行。

表 1. 采样 SARSA 控制的精确策略回报 (30 个 MDP；括号内为样本标准差)。

更新规则	初始回报	最终回报	回报增益	正的 J_{μ} 增益
标准 softmax SARSA	0.104 (0.211)	0.533 (0.117)	0.429 (0.190)	30/30
精确匹配写回	0.104 (0.211)	0.532 (0.117)	0.428 (0.192)	30/30

softmax 学习器平均增益的双侧 Student- t 95% 置信区间为 $[0.358, 0.500]$ 。其贪心策略回报从 0.110 上升到 0.587，而最优回报为 0.621。在最后一次更新时，它的 Q 表与共享轨迹比较器之间的无穷范数差异仅为 2.19×10^{-4} （标准差 5.27×10^{-5} ），二者的贪心策略在 0.996 的状态上相同（标准差 0.020）。在相同冻结 Q 下进行的单步检验中，平均差异为 1.54×10^{-4} ；所有受检步骤均低于相应的有限核误差界。观测到的最大非匹配注意力质量为 7.80×10^{-4} 。这些配对受控结果表明：每个采样任务都获得了正的最终 J_{μ} 增益，同时算子具有很高保真度；但它们并不意味着逐状态策略支配，也不意味着每个随机 SARSA 步骤都单调改进。事实上，中间阶段的评估回报有时会下降。




图 1. 标准 softmax 采样 SARSA 带来正的最终策略回报增益。左：控制更新过程中精确回报变化的均值，阴影表示 95% 置信区间。右：每个配对任务的最终回报增益，并叠加共享轨迹的恒等比较器结果。

5.3 双阶段路径：策略增益与动作尖锐度

第二个实验从采样噪声中分离内部动作聚合的影响。我们使用另外 20 个 MDP，状态数、动作数与折扣因子均保持不变，并根据精确条件期望更新每个状态-动作对。实验从 $Q_0 = 0$ 开始，取 $\alpha = 0.5$ 、状态-动作尖锐度 $\eta = 20$ ，执行 200 次同步更新。贪心 $\arg \max$ 出现并列时，包括初始全零时，选择索引最小的动作。精确最大值核算子作为 oracle 参考；提出的算子则取 $\beta \in \{1, 2, 5, 10, 20\}$ 。最终策略关于所得 Q 表为贪心策略，并使用同一并列处理规则。

初始策略回报的均值为 -0.0569 (标准差 0.262)，而 oracle 达到 0.5209 (标准差 0.151)，增益为 0.5777 (标准差 0.224)。每一种 softmax 温度都在全部 20 个任务上获得正的最终 J_μ 增益。

表 2. 经过 200 次期望更新后的双阶段 softmax 控制 (20 个 MDP 上的均值)。

算子	回报增益	最优回报差距	Q 无穷范数误差	贪心一致率
精确最大值 oracle	0.57774	0	7.48×10^{-13}	1.000
softmax, $\beta = 1$	0.57682	9.25×10^{-4}	0.2465	0.972
softmax, $\beta = 2$	0.57766	7.51×10^{-5}	0.1905	0.989
softmax, $\beta = 5$	0.57766	7.51×10^{-5}	0.08758	0.989
softmax, $\beta = 10$	0.57774	0	0.03441	1.000
softmax, $\beta = 20$	0.57773	8.98×10^{-6}	0.01131	0.994

动作价值误差随 β 增大而降低。观测到的逐状态 softmax 与最大值之差，从 $\beta = 1$ 时的 0.3618 降至 $\beta = 20$ 时的 0.02007，低于相应的理论界 1.386 和 0.06931。贪心策略是 Q 的分段常值函数，因此，即使动作价值误差尚未消失，策略回报也可能已经与 oracle 相同；表中因此同时报告这两个量，而不把 Q 误差当成策略改进的替代指标。




图 2. 双阶段算子获得正的策略回报增益，并趋近贪心动作选择。左：回报增益均值，误差棒为样本标准差；虚线表示精确最大值 oracle。右：观测到的 softmax 与最大值之差始终低于 $\log(|A|)/\beta$ 。

5.4 端到端与有限尖锐度检验

在确定性 fixture 上，literal matrix witness 使用一个 32×20 prompt，实例化文中声明的每个投影与完整 query-by-source mask。所有 mask row 都有非空支持，全部 softmax row 均为有限值且归一化；retrieved value、带符号 residual 坐标与预期 token state 一致，未访问 query 被路由到零值 null token。最终 Q 更新与紧凑实现及显式 frozen-batch 表格参考的最大差异均为 5.55×10^{-17} ；连续六次 singleton update 也与顺序表格 SARSA 一致，八个未访问 pair 保持不变。这是完整构造的 implementation witness，与大规模 control sweep 相互独立。故意降低 retrieval 与 write-back sharpness 到 $(\zeta, \eta) = (2.4, 2.1)$ 时，观测 retrieval error 为 0.425，低于 0.999 的界；完整 end-to-end update error 为 0.250，低于命题 3.7 给出的 1.170 界。

较早的紧凑直接公式检验显示，精确匹配逐对 write-back 误差为 1.11×10^{-16} 。在 control experiment 使用的 $\eta = 12$ 下，观测到的合成单步有限核误差为 8.55×10^{-5} ，低于 2.00×10^{-4} 的计算界。在双阶段实验的 20 次更新尖锐度扫描中，将非匹配质量从 $\eta = 1$ 时的 0.928 降至 $\eta = 10$ 时的 0.00159，使平均 Q 误差从 0.547 降至 0.01158；取 $\eta = 20$ 时仍为 0.01158。这些检验支持有限步 retrieval 与 write-back distortion 分析，但不用于声称 leakage 必然形成不可避免的渐近 error floor。

6. 讨论

6.1 对策略改进问题的直接回答

可以，但结论是本文建立的精确 oracle-routed 构造意义下的“可以”。在路径 I 中，两个 equality-routed retrieval head 从 Q -memory 读取当前与 sampled next-pair value，固定 ReLU map 形成带符号 SARSA residual，final matching head 执行逐对均值 write-back；精确恒等式假设外部 mask 与 visited/null gate。Equality-mask-free 的有限 logit retrieval 与 write-back 在保留 gate 的前提下近似精确版本。闭合外部 operator-policy loop 后，受控任务得到正的最终 J_μ 增益，其中大规模 sweep 运行的是 compact direct-indexing implementation。在路径 II 中，action-softmax head 提供当前 Boltzmann 策略的期望续接价值，并对贪心动作选择给出受控近似。实证主张建立在 before-after J_μ 上，而不是 TD error 下降或逐状态支配。

这一答案不依赖 Q -learning。只要从当前动作价值更新行为策略，SARSA 就已经成为控制方法 [6]。保留基于最大值的路径，只是因为它能证明标准 softmax 也可以在内部执行近似贪心化，而且 Bellman 最优性能够提供更强的邻域保证。

6.2 与线性注意力 SARSA 的关系

Liang 和 Lai [4] 使用线性注意力更新共享参数向量，这需要构造 TD residual 与 feature vector 的样本相关乘积。我们的构造把 Q 直接存于 state-action memory token；标准 softmax head 先检索两个所需标量，再把带符号 residual 路由回匹配 memory token，而不需要动态 residual-feature product。两种表示方式不同，但都实现 SARSA control update。相对于固定策略 softmax TD 构造 [5]，持久化 state-action memory、显式 Q retrieval 与行为策略闭环是关键变化。

6.3 局限性

理论是表格型的，并假设每个状态-动作对有一个持久化 memory token。精确 retrieval 与 write-back 使用外部提供、输入相关的结构化 equality mask 与外部 visited-query/null-token gate；有限 equality-mask-free logit 仍为 gate-assisted 近似。精确网络无 LayerNorm 与 dropout，也不是 decoder-only 因果 Transformer。采样实验在每个 batch 内冻结 Q 与行为策略，直接索引两个 Q 值并使用逐对均值 update；经典 online SARSA convergence 则适用于 GLIE 与逐 pair Robbins-Monro 条件下的 singleton sequential update。固定 block 给出固定步长，因此 variable schedule 需要 block family 或额外 multiplication mechanism。双阶段 expected experiment 具有 full coverage，分离的是 operator bias 而非 finite-trajectory concentration。精确 ϵ -greedy argmax、随机策略采样与环境 action execution 都在 attention block 外。扩展到 learned representation 还必须处理 approximate identifier、learned 或 mask-free routing、support gating、coverage 与 persistent-memory scaling。

7. 结论

标准归一化 softmax 注意力能够支持上下文内策略改进。核心机制是带符号的状态-动作价值写回：注意力权重执行上下文匹配，而正、负 TD 修正仍保留在 value 向量中。

采样 SARSA 构造给出直接的同策略路径。从原始 transition identifier 与 reward 出发，两个 externally equality-routed softmax head 从持久化 Q -memory 检索当前与 sampled next-pair value，显式的两单元 ReLU map 形成带符号 residual，state-action head 再写回已访问的 Q -memory token。外部 visited-query/null-token gate 处理未出现 pair。单例构造生成通常的顺序 SARSA iterates。移除 equality mask 后得到 finite-logit retrieval 与 write-back 近似，但仍保留该 gate。将更新后的价值与下一轮行为策略结合，就闭合了外部 interaction loop，无需在 TD target 中使用最大值。

双阶段构造给出了更强的内部动作选择结果。其有限温度动作聚合是当前 Boltzmann 策略下的期望续接价值；加入奖励与折扣后，即得到条件 Expected-SARSA 目标。随着动作注意力变得尖锐，同一续接价值趋近贪心价值，误差至多为 $\log(|A|)/\beta$ 。将这一偏差与 Bellman 最优算子的压缩性结合，可在理想表格设定中得到 Q^* 周围的邻域保证，以及相应的贪心策略性能界。

实验通过策略行为评估两条路径。大规模单阶段 sweep 用 direct table indexing 取得两个 Q 值，并检验紧凑 residual/write-back control operator 与共享轨迹 exact-match comparator；它不是完整 prompt 网络的运行。独立的 literal matrix witness 验证 full prompt、projections、routing masks、residual states 与 write-back。双阶段紧凑算子则在改变动作与核 sharpness 时与精确 greedy control 比较。两类结果共同表明：sampled on-policy update 能带来最终 policy-return gain；增加一个 stage 后，approximate internal greedification 也能产生该增益。

精确结果仍是对固定 problem size 与 update parameter 的 oracle-routed、fixed-weight token-level 构造。它的双 block residual attention-FFN 网络无 LayerNorm 与 dropout，采用双向结构化注意力而非 decoder-only 因果 attention，并依赖外部提供、输入相关的 equality-routing mask 与外部 visited-query/null-token gate。它没有把 environment simulation 或随机动作 draw 放入 deterministic attention，没有证明 stochastic sampling 下每次更新都单调改进，没有证明 pretrained Transformer 会自动发现路由，也没有给出超出所述 coverage condition 的有限表格保证。扩展到 learned representation、learned 或 mask-free exact routing 以及 finite-trajectory coverage，是主要开放方向。

参考文献

1. J. von Oswald, E. Niklasson, E. Randazzo, J. Sacramento, A. Mordvintsev, A. Zhmoginov, and M. Vladymyrov. Transformers Learn In-Context by Gradient Descent. ICML, 2023. arXiv:2212.07677.
2. E. Akyurek, D. Schuurmans, J. Andreas, T. Ma, and D. Zhou. What Learning Algorithm Is In-Context Learning? Investigations with Linear Models. ICLR, 2023. arXiv:2211.15661.
3. S. Garg, D. Tsipras, P. Liang, and G. Valiant. What Can Transformers Learn In-Context? A Case Study of Simple Function Classes. NeurIPS, 2022. arXiv:2208.01066.
4. H. Liang and L. Lai. Transformers Provably Implement In-Context Reinforcement Learning with Policy Improvement. 2026. arXiv:2605.05755.
5. Z. Xie, X. Liu, C. Chen, S. D. Liu, R. Chandra, and S. Zhang. Beyond Linear Attention: Softmax Transformers Implement In-Context Reinforcement Learning. 2026. arXiv:2605.07333.
6. R. S. Sutton and A. G. Barto. Reinforcement Learning: An Introduction. Second edition, MIT Press, 2018.
7. O. Richter and R. Wattenhofer. Normalized Attention Without Probability Cage. ICLR, 2021. arXiv:2005.09561.
8. P. Velickovic, C. Perivolaropoulos, F. Barbero, and R. Pascanu. Softmax Is Not Enough (for Sharp Size Generalisation). ICLR, 2025. arXiv:2410.01104.