

Introduction 教学注记 (新主线)

引言的六段逻辑

1. **两条前作路线**: Liang-Lai 用 linear attention 做参数化 policy improvement; Xie 用 softmax 做固定策略 TD evaluation。
2. **纠正旧问题**: softmax 正权重不会抹掉 value 中 delta 的负号。
3. **真实难点**: 参数路线要动态生成 deltaphi ; Q-learning 路线要生成 greedy target。
4. **方法选择**: 不强迫 softmax 重现 deltaphi , 而是 token 化 $Q(s,a)$, 直接写回查询值。
5. **理论与实验**: 第一阶段误差 $\log|A|/\beta$, 第二阶段有 kernel/context 误差; 实验逐项隔离。
6. **克制声明**: 不声称单头参数化 Q-learning、不声称 max 对所有改进必要、不使用宽泛 first claim。

读引言时只问三个问题

- 论文维护的是参数 w , 还是每个 query 的 $Q(s,a)$?
- max、delta 和写回分别是在 attention 内、prompt 中还是外部?
- 理论误差究竟来自温度、kernel、采样, 还是未经证明的“表达性不可能”?

更完整推导见 paper_ 教学注记.md。